



Universidade Estadual de Maringá

Departamento de Informática



Trabalho de IIA – Processamento de Linguagem Natural

Modalidade: em grupo de 3 integrantes

Objetivo: utilizar técnicas de PLN para analisar textos científicos.

Materiais:

Escolha de um **termo de busca relevante na computação** e sua respectiva base no Anexo A;
Baixar 12 artigos científicos em pdf;
Utilizar linguagem python, e alguma biblioteca para leitura de pdfs como: PyPDF2, python-pdfbox ou qualquer outra à escolha da equipe;

Descrição do trabalho: modelar uma ontologia sobre a estrutura de um artigo científico, e a partir dela implementar um software que execute as seguintes tarefas:

- **Etapa 1**, fase inicial (20% da nota)
 - ler arquivos pdf de um diretório
 - utilizar uma biblioteca para leitura de pdf (ex.: PyPDF2, python-pdfbox)
 - realizar pré-processamento de texto (remoção de *stop-words*, lematização, *stemming*, se necessário)
 - utilização de modelos de linguagem como *bag-of-words*, n-gramas, etc
 - identifique os 10 termos mais citados nos artigos (não considerando as referências bibliográficas – *references*)
 - extraia as referências bibliográficas
- **Etapa 2**, extrair informações sobre: (20% da nota)
 - Objetivo (*objective*) do artigo (normalmente na introdução), ex.: “The objective of this article is to contribute to the debate on whether or not marketing boards have the capacity to de-crease transaction costs faced by producers with an evaluation of the magnitude of transaction costs incurred by producerswhen selling their milk through a marketing board”
 - Problema (*problem*) do artigo (normalmente na introdução), ex.: “That way, our article overcomes a transaction costs economics’ basic selection problem”
 - método ou metodologia (method, methodology, interviews, survey, content analysis, etc), ex.: “Interviews and surveys were conducted to estimate transaction costs faced by producers marketing through the Qu´ebec milk marketing board in Canada andbilateral contracts in England and Wales in the United Kingdom using the measurement **methodology** of the cost of exchange”
 - Identificar contribuições do artigo (trechos que expressem '*contributes to*'), diferenciando-os claramente dos objetivos.”. ex.: “Our study contributes to this



Universidade Estadual de Maringá

Departamento de Informática



neglected literature while focusing on the comparison of two distinct hybrid coordination mechanisms used in developed countries"

- **Etapa 3** - Salvar os dados extraídos em arquivo, em formato de uma ontologia de artigo científico, utilizando algum dos formatos a seguir (20% da nota):

Linguagem	Característica principal	Legibilidade	Uso típico
RDF/XML	Serialização em XML	Baixa	Compatibilidade antiga
Turtle	Sintaxe compacta	Alta	Definição manual de ontologias
OWL	Lógica descritiva	Média	Ontologias complexas
Frames	Estrutura com slots	Alta	Protégé clássico
JSON-LD	RDF em JSON	Alta	Web semântica, APIs

- **Etapa 4** – Avaliação de desempenho do sistema de extração de informações de artigos científicos (20% da nota).
- **Etapa 5** - Apresentação do trabalho, com base em slides contendo (20% da nota):
 1. apresentação: universidade, curso, disciplina, título do trabalho, equipe, professor
 2. introdução (descrição/modelagem do problema a ser resolvido)
 3. fundamentação (breve)
 4. materiais e método (linguagem, ambiente, listar todas as bibliotecas utilizadas; *pipeline*)
 5. fonte dos dados sobre os experimentos
 6. demonstração prática da análise em artigos adicionais, distintos dos 12 escolhidos
 7. análise da avaliação de desempenho do sistema
 8. conclusões
 9. bibliografias utilizadas: sites, livros, ppts, vídeos, etc.



Universidade Estadual de Maringá

Departamento de Informática



Observações:

Cada equipe deverá aplicar técnicas de visualização de palavras com base na análise realizada, respondendo às seguintes questões:

- palavras mais citadas nos artigos analisados
- nuvem de palavras geral
- técnicas mais mencionadas nos artigos
- evolução temporal nos termos utilizados (em anos diferentes)
- termos que aparecem como trabalhos futuros (normalmente no final da conclusão)

Sugerem-se as seguintes visualizações: nuvem de palavras, gráficos de barras de frequência, *heatmaps*, gráficos de coocorrência de termos, diagramas de similaridade entre artigos, árvores de palavras.

O uso de bibliotecas que implementem modelos de aprendizagem de máquina ou modelos pré-treinados (como *Transformers*, *spaCy*, *scikit-learn*, *TensorFlow*, *PyTorch*, *BERT*, *GPT*, *Word2Vec*, etc.) não é permitido. Caso seja identificado o uso dessas ferramentas, haverá desconto de até **1 ponto da nota** (o trabalho vale de 0 a 5 pontos).

O código fonte, pdfs dos artigos científicos analisados, e slides deverão ser compactados em um único arquivo nomeado com o primeiro nome e as iniciais do sobrenome de cada aluno, separados por "-". O arquivo compactado deve ser compartilhado e enviado um link de download para o e-mail wigarashi@uem.br até a data limite de entrega do trabalho, contendo: título do email – Trabalho 2 de IIA; no corpo do email: o nome completo dos integrantes da equipe e RA. **Trabalhos entregues em atraso terão desconto na nota final.**

A avaliação do trabalho será realizada utilizando os seguintes critérios: originalidade, complexidade do problema abordado, apresentação dos resultados, completude dos itens especificados, português correto, código compilável e executável. **Será utilizado software de verificação de similaridade, assim se houver indícios de cópia de trabalho, os trabalhos envolvidos terão nota 0.**



Universidade Estadual de Maringá

Departamento de Informática



Anexo A – Lista de temas

- Cada equipe deverá escolher um entre os seguintes 13 temas de Computação para realizar sua análise textual, e informar a escolha no classroom:
 - Processamento de Linguagem Natural (NLP) - ieeexplore
 - Computação Quântica - scopus
 - Internet das Coisas (IoT) - sciencedirect
 - Redes Neurais - acm
 - Visão Computacional - ieeexplore
 - Sistemas Multiagentes - scopus
 - Blockchain - sciencedirect
 - Robótica - acm
 - Bioinformática- ieeexplore
 - Segurança Cibernética - scopus
 - Computação na Nuvem - sciencedirect
 - Computação Afetiva - acm
 - Computação Ubíqua- ieeexplore

Todas estas bases têm vários artigos acessíveis dentro da rede da UEM. Caso seja necessário acessar estes arquivos foram da UEM, utilizem o sistema de login CAFE (acesso federado) no portal da Capes, utilizando o login e senha da UEM.