

Ontologia de Artigos Científicos

Cloud Computing

Universidade Estadual de Maringá - Departamento de Informática

Curso: Ciência da Computação

Disciplina: IIA - Introdução à Inteligência Artificial

Professor: Prof. Dr. Wagner Igarashi

Equipe: Caetano (RA: 135846), Lorenzo (RA 133076), Vitor da Rocha (RA 132769)

Sumário

1. Introdução
2. Fundamentação teórica
3. Materiais e métodos
4. Fonte dos dados
5. Visualizações do corpus
6. Demonstração em artigos adicionais
7. Avaliação de desempenho do sistema
8. Conclusões
9. Bibliografia

1. Introdução

O problema

- O volume de artigos científicos publicados cresce mais rápido do que a capacidade humana de lê-los e organizá-los manualmente.
- Ler, classificar e resumir manualmente um corpus de artigos é um processo lento e repetitivo.
- **Pergunta do trabalho:** é possível usar técnicas de PLN (sem modelos de aprendizado de máquina/pré-treinados) para extrair automaticamente a estrutura e o conteúdo essencial de um artigo científico?

Modelagem do problema

Os artigos científicos foram modelados como uma **ontologia** com os seguintes elementos, a serem extraídos automaticamente do PDF:

- Identificação: título, autores, ano, DOI, periódico
- Conteúdo: abstract, palavras-chave, introdução, corpo, conclusão
- Análise: objetivo, problema, metodologia, contribuições, trabalhos futuros
- Referências bibliográficas citadas

O código desenvolvido lê um diretório de PDFs e produz, para cada artigo, uma instância estruturada dessa ontologia.

2. Fundamentação teórica

Modelos de linguagem e pré-processamento

- **Tokenização:** quebra do texto em unidades (palavras/termos)
- **Stop-words:** remoção de palavras de alta frequência e baixo valor semântico (artigos, preposições, conectivos)
- **Lematização** (WordNet): reduz a palavra à sua forma canônica de dicionário (ex.: "*schemes*" → "*scheme*")
- **Stemming** (Porter/Snowball): reduz a palavra ao seu radical, de forma mais agressiva que a lematização (disponível no código, desligado por padrão)
- **Bag-of-Words:** representa o texto pela contagem de frequência de cada termo, ignorando a ordem das palavras
- **N-gramas:** sequências de N termos consecutivos (bigramas, trigramas), úteis para capturar termos técnicos compostos (ex.: "*cloud computing*")

Extração de informação e ontologias

- **Extração de informação baseada em regras (rule-based IE):** uso de expressões regulares e padrões linguísticos para localizar frases que expressam objetivo, problema, metodologia e contribuições.
- **Ontologias e Web Semântica:** estrutura formal de conceitos e relações de um domínio. Dentre os formatos possíveis (RDF/XML, Turtle, OWL, Frames, JSON-LD), o trabalho usa **JSON-LD**, que combina legibilidade com compatibilidade direta com APIs e o vocabulário padronizado do schema.org

3. Materiais e métodos

Linguagem e bibliotecas

Biblioteca	Uso no projeto
Python 3 (stdlib)	Lógica geral do pipeline
<code>PyPDF2</code>	Extração de texto dos PDFs
<code>nltk</code>	Stop-words, lematização (WordNet), stemming
<code>matplotlib</code> + <code>numpy</code>	Gráficos e heatmaps
<code>wordcloud</code>	Nuvens de palavras

Nenhuma biblioteca de aprendizado de máquina ou modelo pré-treinado foi utilizada.

Pipeline do sistema

PDFs (12 artigos)



1. Leitura (PyPDF2) → 2. Limpeza de artefatos de PDF



3. Categorização (regex) → título, autores, seções, referências



4. Pré-processamento → stop-words, lematização



5. Modelos de linguagem → bag-of-words, n-gramas, top termos



6. Extração de informação → objetivo, problema, metodologia, contribuições



7. Exportação da ontologia (JSON-LD) + Visualizações

4. Fonte dos dados

Córpus analisado

- **Tema:** Cloud Computing (Computação em Nuvem)
- **Base:** ScienceDirect
- **Periódico de origem dos 12 artigos:** *Computers & Security* (Elsevier)
- **Período de publicação:** 2014 – 2024
- **Assuntos recorrentes:** auditoria e integridade de dados na nuvem, criptografia baseada em atributos, detecção de intrusão em redes virtuais, forense digital, segurança em IoT, computação móvel-nuvem

Termos de Busca: Cloud Computing

Article Type: Research Articles

Publication Title: Computers & Security

Subject Areas: Computer Science

Os 12 artigos do corpus

Título (resumido)	Ano	Refs.
SNAPS: snapshot based provenance system for VMs in the cloud	2019	11
Security analysis of a public auditing scheme for secure data storage	2023	16
Efficient security framework for detecting intrusions in virtual networks	2019	35
Trust or consequences? Causal effects of perceived risk...	2017	53
Self-Attention conditional GAN for...	2024	32
A survey of cloud computing data integrity schemes	2017	96

Os 12 artigos do corpus (continuação)

Título (resumido)	Ano	Refs.
Sticky policies approach within cloud computing	2017	41
Optimized extreme learning machine for detecting DDoS attacks	2021	32
Cloud computing security: a survey of service-based models	2022	58
Parallel search over encrypted data under attribute-based encryption	2015	22
Achieving an effective, scalable and privacy-preserving data...	2014	29
A self-protecting agents based model for high-performance mobile-cloud	2018	34


Total: 12 artigos, 459 referências bibliográficas extraídas no total.

5. Visualizações do corpus

Palavras mais citadas nos artigos


Termos mais frequentes do corpus (unitermos, excluindo as referências): **data** (1097), **cloud** (986), **user** (610), **scheme** (473), **security** (469), **attack** (396), **model** (394)...

Bigrama mais citado: **"cloud compute"** (142) e **"data integrity"** (122).




Nuvem de palavras geral

A nuvem reforça visualmente o predomínio dos termos relacionados a armazenamento e proteção de dados em nuvem.




Técnicas mais mencionadas nos artigos

Reflete o foco do corpus em integridade e confidencialidade de dados armazenados na nuvem.




Evolução temporal dos termos

- O heatmap mostra a frequência relativa (%) dos termos mais citados, ano a ano, permitindo observar a permanência de termos como *data* e *cloud* ao longo de toda a década analisada. Infelizmente poucos artigos estão sendo usados o que limita a visualização.




Termos em trabalhos futuros

- A seção de trabalhos futuros foi identificada explicitamente em apenas **3 dos 12 artigos (25%)** - muitos artigos do corpus não têm uma subseção de "future work" claramente demarcada na conclusão



Termos em trabalhos futuros




Visualizações complementares

Além do que foi pedido, foi gerado:

- **Heatmap de coocorrência:** quais termos aparecem próximos uns dos outros no texto
- **Similaridade entre artigos:** similaridade de Jaccard entre os conjuntos de termos de cada artigo, em heatmap e em diagrama de rede
- **Árvore de palavras:** contexto (palavras antes/depois) do termo "cloud" no córpus


Visualizações complementares

- Heatmap de coocorrência




Visualizações complementares

- Similaridade entre artigos



Visualizações complementares

- Similaridade entre artigos



Visualizações complementares

- Árvore de palavras

Word Tree - context of "cloud" in the corpus




6. Demonstração prática em artigos adicionais


Demonstração

- A respeito da categorização estrutural, apenas o Ano de Publicação e o *Journal* não foram extraídos, além do DOI de um deles. Porém o restante foi encontrado.
- Enquanto em um dos artigos não foi achado os objetivos e as contribuições, o outro teve todos os dados inferidos.
- É possível observar a importancia de frases padrões como: "the major contributions of this paper..." e "In future work...".

Palavras mais citadas nos artigos de Demonstração




Técnicas mais mencionadas nos artigos de Demonstração



Nuvem de palavras geral

Word Cloud - Cloud Computing & Security Corpus



7. Avaliação de desempenho do sistema

Metodologia de avaliação

A avaliação foi feita em duas frentes:

1. **Quantitativa** - taxa de cobertura: em quantos artigos cada campo da ontologia foi efetivamente extraído (não vazio), calculada diretamente sobre as saídas reais do sistema (`categorized_output.json` e `extraction_output.json`) para os 12 artigos do corpus
2. **Qualitativa** - leitura manual de uma amostra das frases extraídas, comparando-as com o conteúdo real do artigo, para identificar acertos e limitações dos padrões de regex utilizados

Resultado quantitativo - Etapa 1 (categorização)

Campo	Cobertura
Título	100% (12/12)
Autores	100% (12/12) - média de 4,0 autores/artigo
Abstract	100% (12/12) - média de 1.364 caracteres
Palavras-chave	100% (12/12) - média de 5,4 termos/artigo
Ano de publicação	100% (12/12)
DOI	83% (10/12)
Referências bibliográficas	100% (12/12) - 459 no total, média 38,2/artigo

Resultado quantitativo - Etapa 1 (categorização)

A categorização estrutural (campos bibliográficos) teve **desempenho muito alto**, pois esses campos seguem um padrão visual/textual bastante regular nos artigos da Elsevier/ScienceDirect.

Resultado quantitativo - Etapa 2 (extração de informação)

Campo	Cobertura	Méd. frases/artigo
Objetivo	92% (11/12)	1,2
Problema	100% (12/12)	2,0
Metodologia	100% (12/12)	3,0
Contribuições	50% (6/12)	0,7
Trabalhos futuros	25% (3/12)	0,2

Apenas 2 dos 12 artigos (17%) tiveram os 5 campos extraídos simultaneamente.

Exemplos de acerto

Objetivo (*intrusion detection em redes virtuais*):

"In this paper, we propose a hypervisor level distributed network security (HLDNS) framework which is deployed on each processing server of cloud computing."

Trabalhos futuros (*mesmo artigo*):

"Conclusions and future work - Network security is a major concern for wide adoption of the cloud computing."

Esses padrões ("in this paper, we propose...", "future work") são bastante **convencionais na escrita acadêmica em inglês**, por isso o sistema os reconhece com boa precisão.

Exemplos de limitação

Problema identificado (*artigo sobre auditoria de dados*):

"...to handle the problem of user revocation..., Wang et al. (2015) proposed a novel scheme, named Panda."

Esta frase descreve o problema resolvido por um **trabalho relacionado** (Wang et al., 2015), não necessariamente o problema do próprio artigo - um falso positivo típico de uma extração baseada apenas em palavras-chave ("problem"), sem compreensão de quem é o sujeito da frase.

- **Contribuições** (50% de cobertura) e **trabalhos futuros** (25%) tiveram desempenho mais baixo: a frase exata "contributes to" é rara, e nem todos os artigos têm uma subseção de "future work" explícita.

Discussão dos resultados

- O sistema tem **alto desempenho em campos estruturais e bem padronizados** (título, autores, abstract, keywords, referências) - domínio onde regex sobre o layout do PDF funciona muito bem.
- O sistema tem **desempenho variável em campos semânticos livres** (objetivo, problema, metodologia, contribuições, trabalhos futuros) - domínio onde a linguagem natural tem muito mais variação, e uma abordagem por regras não consegue cobrir todos os estilos de escrita.
- Os padrões "amplos" (fallback) implementados em `extraction.py` aumentam a cobertura de Objetivo e Contribuições, mas podem reduzir a precisão em alguns casos (como no exemplo de falso positivo acima).

8. Conclusões

Conclusões

- Foi possível modelar e implementar uma ontologia de artigo científico e um pipeline completo de PLN **sem o uso de modelos de aprendizado de máquina**, usando apenas pré-processamento clássico, modelos de linguagem estatísticos (BoW/n-gramas) e extração de informação baseada em regras.
- O sistema é **muito confiável para metadados estruturais** (título, autores, abstract, referências) e **parcialmente confiável para conteúdo semântico livre** (objetivo, problema, metodologia, contribuições, trabalhos futuros), com cobertura entre 25% e 100% dependendo do campo.

Conclusões

- A ontologia em **JSON-LD** se mostrou um formato prático para representar os artigos de forma legível e interoperável com vocabulários da Web Semântica (schema.org).
- Limitações: dependência do layout do periódico de origem, e sensibilidade dos padrões de regex a formas alternativas de expressar a mesma ideia.

9. Bibliografia

Bibliografia

- PyPDF2 - documentação oficial: <https://pypdf2.readthedocs.io/>
- NLTK - documentação oficial: <https://www.nltk.org/>
- Matplotlib - documentação oficial: <https://matplotlib.org/>
- WordCloud (Python) - https://github.com/amueller/word_cloud
- JSON-LD - especificação W3C: <https://www.w3.org/TR/json-ld/>
- Schema.org - vocabulário para dados estruturados: <https://schema.org/>
- Enunciado do trabalho e slides do prof. - UEM, Departamento de Informática

Obrigado!